

第四章 大数定律与中心极限定理

本章主要是解决概率论中的一些基本问题，如频率稳定性，正态分布的普适性问题。

§4.1 随机变量序列的两种收敛性

与数列的收敛性不同，随机变量序列的收敛性有多种，依概率收敛 (Convergence in Probability)、按分布收敛 (Convergence in Distribution)、几乎处处收敛 (Almost Everywhere Convergence)、依均方收敛 (Convergence in Mean Square) 等。本节介绍依概率收敛和按分布收敛。

4.1.1 依概率收敛 (Convergence in Probability)

数学分析中的极限 $\lim_{n \rightarrow \infty} x_n = a$ ，也就是对任意给定的 $\varepsilon > 0$ ，存在正整数 N ，当 $n > N$ 时， $|x_n - a| < \varepsilon$ 恒成立。在概率论中频率与概率的关系也是一种极限，但与数学分析中的极限不同。

不妨设事件 A 在每次试验中发生的概率为 p ，在 n 重伯努利试验中的发生次数为 S_n ，即发生的频率为 $\frac{S_n}{n}$ 。直观上，随 n 的无限增大，频率 $\frac{S_n}{n}$ 将以概率 p 为“极限”，但对很小的正数 $\varepsilon > 0$ ，无论 n 有多大，都不能使得 $\left| \frac{S_n}{n} - p \right| < \varepsilon$ 恒成立。如掷硬币试验，正面朝上的概率 $p = 0.5$ ，掷 n 次硬币，正面朝上的次数为 S_n ，理论上，无论 n 有多大，都有可能次次正面朝上（当然发生的概率非常小），即频率 $\frac{S_n}{n} = 1$ 。对给定的正数 $\varepsilon = 0.1$ ，无论 n 有多大，都可能有 $\left| \frac{S_n}{n} - 0.5 \right| = 0.5 > \varepsilon = 0.1$ 。

不过，当 n 很大时， $\left| \frac{S_n}{n} - p \right| < \varepsilon$ 虽然不是恒成立，但可以看出成立的概率将很接近于 1，可以证明，

当 $n \rightarrow +\infty$ 时， $\left| \frac{S_n}{n} - p \right| < \varepsilon$ 成立的概率将趋于 1，即 $\lim_{n \rightarrow +\infty} P\left\{ \left| \frac{S_n}{n} - p \right| < \varepsilon \right\} = 1$ 。

如果随机变量序列 $\{X_n\}$ 和常数 a ，对任意给定的 $\varepsilon > 0$ ，满足 $\lim_{n \rightarrow +\infty} P\{|X_n - a| < \varepsilon\} = 1$ ，则称 $\{X_n\}$ 依概率收敛于 a ，这就是直观上所说的 X_n 稳定于 a 。

定义 （依概率收敛）设 $\{X_n\}$ 是一个随机变量序列， X 是一个随机变量。如果对任意的 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow +\infty} P\{|X_n - X| < \varepsilon\} = 1。$$

则称 $\{X_n\}$ 依概率收敛于 X ，记为 $X_n \xrightarrow{P} X$ 。

定理 收敛于常数时，四则运算保持依概率收敛性。若 $X_n \xrightarrow{P} a$ ， $Y_n \xrightarrow{P} b$ ，则

$$(1) X_n \pm Y_n \xrightarrow{P} a \pm b; (2) X_n Y_n \xrightarrow{P} ab; (3) \frac{X_n}{Y_n} \xrightarrow{P} \frac{a}{b}, (b \neq 0)。$$

证明: (1) 因

$$|(X_n \pm Y_n) - (a \pm b)| = |(X_n - a) \pm (Y_n - b)| \leq |X_n - a| + |Y_n - b|,$$

对任意的 $\varepsilon > 0$, 有

$$\{|(X_n \pm Y_n) - (a \pm b)| \geq \varepsilon\} \subset \left\{|X_n - a| \geq \frac{\varepsilon}{2}\right\} \cup \left\{|Y_n - b| \geq \frac{\varepsilon}{2}\right\}$$

由概率的单调性和半可加性可得

$$0 \leq P\{|(X_n \pm Y_n) - (a \pm b)| \geq \varepsilon\} \leq P\left\{|X_n - a| \geq \frac{\varepsilon}{2}\right\} + P\left\{|Y_n - b| \geq \frac{\varepsilon}{2}\right\},$$

又因 $X_n \xrightarrow{P} a$, $Y_n \xrightarrow{P} b$, 有

$$\lim_{n \rightarrow +\infty} P\left\{|X_n - a| \geq \frac{\varepsilon}{2}\right\} = 0, \quad \lim_{n \rightarrow +\infty} P\left\{|Y_n - b| \geq \frac{\varepsilon}{2}\right\} = 0,$$

故 $\lim_{n \rightarrow +\infty} P\{|(X_n \pm Y_n) - (a \pm b)| \geq \varepsilon\} = 0$, 即 $X_n \pm Y_n \xrightarrow{P} a \pm b$;

(2) 因

$$|X_n Y_n - ab| = |(X_n - a)Y_n + a(Y_n - b)| \leq |X_n - a| \cdot |Y_n| + |a| \cdot |Y_n - b|,$$

对任意的 $\varepsilon > 0$, 有

$$\{|X_n Y_n - ab| \geq \varepsilon\} \subset \left\{|X_n - a| \cdot |Y_n| \geq \frac{\varepsilon}{2}\right\} \cup \left\{|a| \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\}.$$

由概率的单调性和半可加性可得

$$0 \leq P\{|X_n Y_n - ab| \geq \varepsilon\} \leq P\left\{|X_n - a| \cdot |Y_n| \geq \frac{\varepsilon}{2}\right\} + P\left\{|a| \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\}.$$

当 $a = 0$ 时, $\left\{|a| \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\} = \emptyset$; 当 $a \neq 0$ 时, $\left\{|a| \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\} = \left\{|Y_n - b| \geq \frac{\varepsilon}{2|a|}\right\}$, 因 $Y_n \xrightarrow{P} b$,

有 $\lim_{n \rightarrow +\infty} P\left\{|Y_n - b| \geq \frac{\varepsilon}{2|a|}\right\} = 0$ 。因此, 总有 $\lim_{n \rightarrow +\infty} P\left\{|a| \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\} = 0$ 。

对任意的正数 $M > 0$, 有

$$\left\{|X_n - a| \cdot |Y_n| \geq \frac{\varepsilon}{2}\right\} \subset \{|Y_n| \geq M\} \cup \left\{|X_n - a| \geq \frac{\varepsilon}{2M}\right\},$$

可得

$$0 \leq P\left\{|X_n - a| \cdot |Y_n| \geq \frac{\varepsilon}{2}\right\} \leq P\{|Y_n| \geq M\} + P\left\{|X_n - a| \geq \frac{\varepsilon}{2M}\right\},$$

因 $Y_n \xrightarrow{P} b$, 有 $\lim_{n \rightarrow +\infty} P\{|Y_n - b| \geq 1\} = 0$ 。而 $\{|Y_n - b| \geq 1\} = \{Y_n \leq b - 1\} \cup \{Y_n \geq b + 1\}$, 有 $\{|Y_n| \geq |b| + 1\} \subset$

$\{|Y_n - b| \geq 1\}$, 即

$$0 \leq P\{|Y_n| \geq |b| + 1\} \leq P\{|Y_n - b| \geq 1\},$$

可得 $\lim_{n \rightarrow +\infty} P\{|Y_n| \geq |b| + 1\} = 0$ 。取 $M = |b| + 1$ ，有

$$0 \leq P\left\{|X_n - a| \cdot |Y_n| \geq \frac{\varepsilon}{2}\right\} \leq P\{|Y_n| \geq |b| + 1\} + P\left\{|X_n - a| \geq \frac{\varepsilon}{2(|b| + 1)}\right\},$$

因 $X_n \xrightarrow{P} a$ ，有 $\lim_{n \rightarrow +\infty} P\left\{|X_n - a| \geq \frac{\varepsilon}{2(|b| + 1)}\right\} = 0$ ，可得

$$\lim_{n \rightarrow +\infty} P\left\{|X_n - a| \cdot |Y_n| \geq \frac{\varepsilon}{2}\right\} = 0。$$

故 $\lim_{n \rightarrow +\infty} P\{|X_n Y_n - ab| \geq \varepsilon\} = 0$ ，即 $X_n Y_n \xrightarrow{P} ab$ ；

(3) 因

$$\left|\frac{X_n}{Y_n} - \frac{a}{b}\right| = \left|\frac{bX_n - aY_n}{bY_n}\right| = \frac{|b(X_n - a) - a(Y_n - b)|}{|bY_n|} \leq \frac{|b| \cdot |X_n - a| + |a| \cdot |Y_n - b|}{|b| \cdot |Y_n|},$$

对任意的 $\varepsilon > 0$ ，有

$$\left\{\left|\frac{X_n}{Y_n} - \frac{a}{b}\right| \geq \varepsilon\right\} \subset \left\{\frac{1}{|Y_n|} \cdot |X_n - a| \geq \frac{\varepsilon}{2}\right\} \cup \left\{\frac{|a|}{|b| \cdot |Y_n|} \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\}。$$

由概率的单调性和半可加性可得

$$0 \leq P\left\{\left|\frac{X_n}{Y_n} - \frac{a}{b}\right| \geq \varepsilon\right\} \leq P\left\{\frac{1}{|Y_n|} \cdot |X_n - a| \geq \frac{\varepsilon}{2}\right\} + P\left\{\frac{|a|}{|b| \cdot |Y_n|} \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\}$$

因 $Y_n \xrightarrow{P} b$ ， $b \neq 0$ ，有 $\lim_{n \rightarrow +\infty} P\left\{|Y_n - b| \geq \frac{|b|}{2}\right\} = 0$ 。而 $\left\{|Y_n - b| \geq \frac{|b|}{2}\right\} = \left\{Y_n \leq b - \frac{|b|}{2}\right\} \cup \left\{Y_n \geq b + \frac{|b|}{2}\right\}$ ，

有 $\left\{|Y_n| \leq \frac{|b|}{2}\right\} \subset \left\{|Y_n - b| \geq \frac{|b|}{2}\right\}$ ，即

$$0 \leq P\left\{|Y_n| \leq \frac{|b|}{2}\right\} \leq P\left\{|Y_n - b| \geq \frac{|b|}{2}\right\},$$

可得 $\lim_{n \rightarrow +\infty} P\left\{|Y_n| \leq \frac{|b|}{2}\right\} = 0$ 。

因

$$\left\{\frac{1}{|Y_n|} \cdot |X_n - a| \geq \frac{\varepsilon}{2}\right\} \subset \left\{|Y_n| \leq \frac{|b|}{2}\right\} \cup \left\{|X_n - a| \geq \frac{|b|\varepsilon}{4}\right\}$$

可得

$$0 \leq P\left\{\frac{1}{|Y_n|} \cdot |X_n - a| \geq \frac{\varepsilon}{2}\right\} \leq P\left\{|Y_n| \leq \frac{|b|}{2}\right\} + P\left\{|X_n - a| \geq \frac{|b|\varepsilon}{4}\right\},$$

因 $X_n \xrightarrow{P} a$, 有 $\lim_{n \rightarrow +\infty} P\left\{|X_n - a| \geq \frac{|b|\varepsilon}{4}\right\} = 0$, 可得

$$\lim_{n \rightarrow +\infty} P\left\{\frac{1}{|Y_n|} \cdot |X_n - a| \geq \frac{\varepsilon}{2}\right\} = 0.$$

当 $a = 0$ 时, $\left\{\frac{|a|}{|b| \cdot |Y_n|} \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\} = \emptyset$; 当 $a \neq 0$ 时,

$$\left\{\frac{|a|}{|b| \cdot |Y_n|} \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\} \subset \left\{|Y_n| \leq \frac{|b|}{2}\right\} \cup \left\{|X_n - a| \geq \frac{b^2\varepsilon}{4|a|}\right\},$$

可得

$$0 \leq P\left\{\frac{|a|}{|b| \cdot |Y_n|} \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\} \leq P\left\{|Y_n| \leq \frac{|b|}{2}\right\} + P\left\{|X_n - a| \geq \frac{b^2\varepsilon}{4|a|}\right\},$$

因 $X_n \xrightarrow{P} a$, 有 $\lim_{n \rightarrow +\infty} P\left\{|X_n - a| \geq \frac{b^2\varepsilon}{4|a|}\right\} = 0$ 。因此, 总有

$$\lim_{n \rightarrow +\infty} P\left\{\frac{|a|}{|b| \cdot |Y_n|} \cdot |Y_n - b| \geq \frac{\varepsilon}{2}\right\} = 0.$$

故 $\lim_{n \rightarrow +\infty} P\left\{\left|\frac{X_n}{Y_n} - \frac{a}{b}\right| \geq \varepsilon\right\} = 0$, 即 $\frac{X_n}{Y_n} \xrightarrow{P} \frac{a}{b}$ 。

4.1.2 按分布收敛 (Convergence in Distribution)、弱收敛 (Weak Convergence)

随机变量的特性由其分布函数完全确定, 对于一个随机变量序列 $\{X_n\}$ 需要考虑其分布函数序列 $\{F_n(x)\}$ 收敛情况。但即使 $\{F_n(x)\}$ 处处收敛, 其极限函数不一定是一个分布函数。

如 X_n 服从均匀分布 $U\left(-\frac{1}{n}, \frac{1}{n}\right)$, 当 $n \rightarrow +\infty$ 时, 直观上可看出 X_n 将“收敛于”在常数 0 处单点分布

的随机变量 X 。但 X_n 与 X 的分布函数 $F_n(x)$ 与 $F(x)$ 分别为

$$F_n(x) = \begin{cases} 0, & x < -\frac{1}{n}; \\ \frac{nx+1}{2}, & -\frac{1}{n} \leq x < \frac{1}{n}; \\ 1, & x \geq \frac{1}{n}. \end{cases}$$

$$F(x) = \begin{cases} 0, & x < 0; \\ 1, & x \geq 0. \end{cases}$$

而

$$\lim_{n \rightarrow +\infty} F_n(x) = \begin{cases} 0, & x < 0; \\ \frac{1}{2}, & x = 0; \\ 1, & x > 0. \end{cases}$$

不满足右连续性，不是一个分布函数， $\lim_{n \rightarrow +\infty} F_n(x) \neq F(x)$ 。

可见，分布函数序列 $\{F_n(x)\}$ 的极限函数不一定是一个分布函数，但该极限函数与一个分布函数在连续点处是相同的。因此，只要求 $\{F_n(x)\}$ 在分布函数 $F(x)$ 的连续点处收敛于 $F(x)$ 。

定义 设随机变量序列 $\{X_n\}$ 与随机变量 X ，分布函数分别为 $F_n(x)$ 与 $F(x)$ ，如果对于 $F(x)$ 的任一连续点 x ，都有

$$\lim_{n \rightarrow +\infty} F_n(x) = F(x),$$

则称 $\{F_n(x)\}$ 弱收敛于 $F(x)$ ，记为 $F_n(x) \xrightarrow{w} F(x)$ ；也称 $\{X_n\}$ 按分布收敛于 X ，记为 $X_n \xrightarrow{L} X$ 。

当 $\{X_n\}$ 按分布收敛于 X 时，又称 $n \rightarrow +\infty$ 时， $\{X_n\}$ 的极限分布是 X 的分布。

由于分布函数 $F(x)$ 单调不减，不连续点最多只有可列个。这样，若 $F_n(x) \xrightarrow{w} F(x)$ ，则 $\{F_n(x)\}$ 不收敛于 $F(x)$ 的点最多只有可列个。

两种收敛的关系是依概率收敛必然按分布收敛，但按分布收敛不一定有依概率收敛。

定理 依概率收敛必然按分布收敛，即 $X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{L} X$ 。

证明：因 $X_n \xrightarrow{P} X$ ，则对任意的 $\varepsilon > 0$ ，有 $\lim_{n \rightarrow +\infty} P\{|X_n - X| \geq \varepsilon\} = 0$ 。设 x 是 $F(x)$ 的任一连续点，有

$$\{X \leq x - \varepsilon\} \subset \{X_n \leq x\} \cup \{X_n - X \geq \varepsilon\},$$

可得

$$F(x - \varepsilon) = P\{X \leq x - \varepsilon\} \leq P\{X_n \leq x\} + P\{X_n - X \geq \varepsilon\} = F_n(x) + P\{X_n - X \geq \varepsilon\},$$

因 $0 \leq P\{X_n - X \geq \varepsilon\} \leq P\{|X_n - X| \geq \varepsilon\}$ 且 $\lim_{n \rightarrow +\infty} P\{|X_n - X| \geq \varepsilon\} = 0$ ，则 $F(x - \varepsilon)$ 不超过 $F_n(x)$ 的任一收敛

子序列的极限，即 $F(x - \varepsilon) \leq \varliminf_{n \rightarrow +\infty} F_n(x)$ ，再令 $\varepsilon \rightarrow 0^+$ ，有 $F(x - 0) \leq \varliminf_{n \rightarrow +\infty} F_n(x)$ ；

又因

$$\{X_n \leq x\} \subset \{X \leq x + \varepsilon\} \cup \{X - X_n \geq \varepsilon\},$$

可得

$$F_n(x) = P\{X_n \leq x\} \leq P\{X \leq x + \varepsilon\} + P\{X - X_n \geq \varepsilon\} = F(x + \varepsilon) + P\{X - X_n \geq \varepsilon\},$$

因 $0 \leq P\{X - X_n \geq \varepsilon\} \leq P\{|X_n - X| \geq \varepsilon\}$ 且 $\lim_{n \rightarrow +\infty} P\{|X_n - X| \geq \varepsilon\} = 0$ ，则 $F_n(x)$ 的任一收敛子序列的极限不

超过 $F(x + \varepsilon)$ ，即 $\overline{\lim}_{n \rightarrow +\infty} F_n(x) \leq F(x + \varepsilon)$ ，再令 $\varepsilon \rightarrow 0^+$ ，有 $\overline{\lim}_{n \rightarrow +\infty} F_n(x) \leq F(x + 0)$ 。从而

$$F(x-0) \leq \varliminf_{n \rightarrow +\infty} F_n(x) \leq \overline{\varliminf_{n \rightarrow +\infty} F_n(x)} \leq F(x+0),$$

因 x 是 $F(x)$ 的任一连续点, 有 $F(x-0) = F(x+0) = F(x)$, 则

$$\varliminf_{n \rightarrow +\infty} F_n(x) = \overline{\varliminf_{n \rightarrow +\infty} F_n(x)} = F(x),$$

故 $\lim_{n \rightarrow +\infty} F_n(x) = F(x)$, 即 $X_n \xrightarrow{L} X$ 。

但按分布收敛不一定有依概率收敛, 如随机变量 X 与随机变量序列 $\{X_n\}$ 独立同分布, 都服从标准正态分布 $N(0, 1)$, 则分布函数 $F(x)$ 与 $F_n(x)$ 相同, 都是 $\Phi(x)$, 当然有 $F_n(x) \xrightarrow{w} F(x)$, 即 $X_n \xrightarrow{L} X$ 。但因为 $X_n - X$ 服从正态分布, 且 $E(X_n - X) = 0$, $\text{Var}(X_n - X) = 2$, 即 $X_n - X \sim N(0, 2)$, 对任意的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow +\infty} P\{|X_n - X| \geq \varepsilon\} = 2 \lim_{n \rightarrow +\infty} P\{X_n - X \geq \varepsilon\} = 2 - 2\Phi\left(\frac{\varepsilon}{\sqrt{2}}\right) > 0,$$

故 $\{X_n\}$ 不是依概率收敛于 X 。

事实上, 按分布收敛只是对随机变量序列的分布有要求, 而对于随机变量取值之间的关系没有要求, 而依概率收敛则更进一步对随机变量取值之间的关系有要求。

不过, 当极限为常数时, 依概率收敛的充分必要条件是按分布收敛。

定理 当极限为常数时, 依概率收敛的充分必要条件是按分布收敛, 即 $X_n \xrightarrow{P} c \Leftrightarrow X_n \xrightarrow{L} c$ 。

证明: 必要性前面定理已证明, 再证明充分性。设 $X_n \xrightarrow{L} c$, 且 X_n 的分布函数为 $F_n(x)$ 。而常数 c 为单点分布, 其分布函数为

$$F(x) = \begin{cases} 0, & x < c; \\ 1, & x \geq c. \end{cases}$$

当 $x \neq c$ 时, x 是 $F(x)$ 的连续点, $F_n(x)$ 收敛于 $F(x)$ 。若 $x < c$, $\lim_{n \rightarrow +\infty} F_n(x) = 0$; 若 $x > c$, $\lim_{n \rightarrow +\infty} F_n(x) = 1$ 。

则

$$\begin{aligned} 1 &\geq P\{|X_n - c| < \varepsilon\} = P\{c - \varepsilon < X_n < c + \varepsilon\} \geq P\left\{c - \varepsilon < X_n \leq c + \frac{\varepsilon}{2}\right\} \\ &= F_n\left(c + \frac{\varepsilon}{2}\right) - F_n(c - \varepsilon), \end{aligned}$$

因

$$\lim_{n \rightarrow +\infty} \left[F_n\left(c + \frac{\varepsilon}{2}\right) - F_n(c - \varepsilon) \right] = 1,$$

故由夹逼准则 (Squeeze Rule) 可得 $\lim_{n \rightarrow +\infty} P\{|X_n - c| < \varepsilon\} = 1$, 即 $X_n \xrightarrow{P} c$ 。

§4.2 特征函数

现实生活中, 独立随机变量和广泛存在, 它在概率论中具有重要地位, 但其分布的计算需要用到卷积运算。而函数 $f(x)$ 的傅立叶变换 (Fourier Transformation) $\varphi(t) = \int_{-\infty}^{+\infty} e^{itx} f(x) dx$ (其中 $i = \sqrt{-1}$ 是虚数单位) 可将函数复杂的卷积运算转换为简单的乘法运算, 并且可用傅立叶逆变换 (Inverse Fourier Transform) 将 $\varphi(t)$ 还原为 $f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-itx} \varphi(t) dt$ 。

对连续随机变量 X 的密度函数 $p(x)$ 作傅立叶变换, 就是数学期望 $E(e^{itX})$, 将该期望值称为随机变量 X 的特征函数。

4.2.1 特征函数的定义

定义 设 X 是一个随机变量, 称

$$\varphi(t) = E(e^{itX}), \quad -\infty < t < +\infty$$

为 X 的特征函数 (Characteristic Function); 又称

$$M(u) = E(e^{iuX}), \quad -\infty < u < +\infty$$

为 X 的矩母函数 (Moment-generating Function)。

由欧拉公式 $e^{i\theta} = \cos \theta + i \sin \theta$ 可知 $|e^{itX}| = 1$, 所以特征函数 $\varphi(t) = E(e^{itX})$ 总是存在。

对于离散随机变量, 设 X 的分布列为 $P\{X = x_k\} = p_k, \quad k = 1, 2, \dots$, 则 X 的特征函数为

$$\varphi(t) = \sum_{k=1}^{+\infty} e^{itx_k} p_k, \quad -\infty < t < +\infty;$$

对于连续随机变量, 设 X 的密度函数为 $p(x)$, 则 X 的特征函数为

$$\varphi(t) = \int_{-\infty}^{+\infty} e^{itx} p(x) dx, \quad -\infty < t < +\infty。$$

常用分布的特征函数

(1) 单点分布: 分布列 $P\{X = a\} = 1$, 特征函数为

$$\varphi(t) = e^{iat};$$

(2) 二项分布 $b(n, p)$: 分布列 $P\{X = k\} = C_n^k p^k (1-p)^{n-k}, \quad k = 0, 1, 2, \dots, n$, 特征函数为

$$\varphi(t) = \sum_{k=0}^n e^{ikt} \cdot C_n^k p^k (1-p)^{n-k} = \sum_{k=0}^n e^{ikt} \cdot C_n^k (pe^{it})^k (1-p)^{n-k} = (1-p + pe^{it})^n;$$

特别是, 当 $n=1$ 时, 两点分布, 分布列 $P\{X=1\} = p, \quad P\{X=0\} = 1-p$, 特征函数为

$$\varphi(t) = 1-p + pe^{it};$$

(3) 泊松分布 $P(\lambda)$: 分布列 $P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots$, 特征函数为

$$\varphi(t) = \sum_{k=0}^{+\infty} e^{ikt} \cdot \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \cdot \sum_{k=0}^{+\infty} \frac{(\lambda e^{it})^k}{k!} = e^{-\lambda} \cdot e^{\lambda e^{it}} = e^{\lambda(e^{it}-1)};$$

(4) 均匀分布 $U(a, b)$: 密度函数 $p(x) = \frac{1}{b-a}$, $a < x < b$, 特征函数为

$$\varphi(t) = \int_a^b e^{itx} \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \cdot \frac{e^{itx}}{it} \Big|_a^b = \frac{e^{ibt} - e^{iat}}{it(b-a)};$$

(5) 指数分布 $Exp(\lambda)$: 密度函数 $p(x) = \lambda e^{-\lambda x}$, $x > 0$, 特征函数为

$$\varphi(t) = \int_0^{+\infty} e^{itx} \cdot \lambda e^{-\lambda x} dx = \int_0^{+\infty} \lambda e^{-(\lambda-it)x} dx = \lambda \cdot \frac{e^{-(\lambda-it)x}}{-(\lambda-it)} \Big|_0^{+\infty} = \frac{\lambda}{\lambda-it};$$

(6) 伽玛分布 $Ga(\alpha, \lambda)$: 密度函数 $p(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$, $x > 0$, 特征函数为

$$\begin{aligned} \varphi(t) &= \int_0^{+\infty} e^{itx} \cdot \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} dx = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^{+\infty} x^{\alpha-1} e^{-(\lambda-it)x} dx = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^{+\infty} \left(\frac{y}{\lambda-it}\right)^{\alpha-1} e^{-y} \cdot \frac{dy}{\lambda-it} \\ &= \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot \frac{1}{(\lambda-it)^\alpha} \int_0^{+\infty} y^{\alpha-1} e^{-y} dy = \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot \frac{1}{(\lambda-it)^\alpha} \Gamma(\alpha) = \left(\frac{\lambda}{\lambda-it}\right)^\alpha; \end{aligned}$$

(7) 标准正态分布 $N(0, 1)$: 密度函数 $p(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$, $-\infty < x < +\infty$, 特征函数为

$$\varphi(t) = \int_{-\infty}^{+\infty} e^{itx} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2-2itx}{2}} dx = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-it)^2}{2}} \cdot e^{-\frac{t^2}{2}} dx = e^{-\frac{t^2}{2}}.$$

4.2.2 特征函数的性质

特征函数具有以下性质:

- (1) $|\varphi(t)| \leq \varphi(0) = 1$;
- (2) $\varphi(-t) = \overline{\varphi(t)}$, 其中 $\overline{\varphi(t)}$ 表示 $\varphi(t)$ 的共轭复数;
- (3) 设 a, b 为常数, 则 $\varphi_{aX+b}(t) = e^{ibt} \varphi_X(at)$;
- (4) 若 X 与 Y 相互独立, 则 $\varphi_{X+Y}(t) = \varphi_X(t) \cdot \varphi_Y(t)$;
- (5) 若 X 的 l 阶矩存在, 则 X 的特征函数 l 阶可导, 且对 $1 \leq k \leq l$, 有 $\varphi^{(k)}(0) = i^k E(X^k)$;
- (6) 特征函数 $\varphi(t)$ 半正定, 即对任意一组互不相同的实数 t_1, t_2, \dots, t_n , 矩阵 $(\varphi(t_i - t_j))_{n \times n}$ 半正定;
- (7) 特征函数 $\varphi(t)$ 一致连续, 即对任意正数 $\varepsilon > 0$, 存在 $\delta > 0$, 当 $|h| < \delta$ 时, 有 $|\varphi(t+h) - \varphi(t)| < \varepsilon$;
- (8) 随机变量的分布函数由其特征函数唯一确定。

证明: (1) 因

$$|\varphi(t)| = |E(e^{itX})| \leq E(|e^{itX}|) = E(1) = 1,$$

且 $\varphi(0) = E(e^0) = 1$, 故 $|\varphi(t)| \leq \varphi(0) = 1$;

(2) 由欧拉公式可得

$$\varphi(-t) = E(e^{-itX}) = E(\cos tX - i \sin tX) = \overline{E(\cos tX) + iE(\sin tX)} = \overline{E(e^{itX})} = \overline{\varphi(t)};$$

(3) 因 a, b 为常数, 则

$$\varphi_{aX+b}(t) = E(e^{it(aX+b)}) = E(e^{itaX} \cdot e^{itb}) = e^{ibt} E(e^{itaX}) = e^{ibt} \varphi_X(at);$$

(4) 因 X 与 Y 相互独立, 则

$$\varphi_{X+Y}(t) = E(e^{it(X+Y)}) = E(e^{itX} \cdot e^{itY}) = E(e^{itX})E(e^{itY}) = \varphi_X(t)\varphi_Y(t);$$

注: 此性质可推广到多个随机变量, 设 X_1, X_2, \dots, X_n 相互独立且 $X = X_1 + X_2 + \dots + X_n$, 则

$$\varphi_X(t) = \varphi_{X_1}(t)\varphi_{X_2}(t)\cdots\varphi_{X_n}(t)。$$

(5) 因 X 的 l 阶矩存在, 对 $1 \leq k \leq l$, 有 X 的 k 阶矩存在。又因

$$\frac{d^k}{dt^k}(e^{itX}) = (iX)^k \cdot e^{itX}, \quad |(iX)^k \cdot e^{itX}| = |i^k| \cdot |X^k| \cdot |e^{itX}| = |X^k|,$$

可得 $E[(iX)^k \cdot e^{itX}]$ 对 $-\infty < t < +\infty$ 都存在。将期望看作积分, 即该含参变量积分一致可积, 可知求导与积分可交换次序, 可得

$$\varphi^{(k)}(t) = E\left[\frac{d^k}{dt^k}(e^{itX})\right] = E[(iX)^k \cdot e^{itX}] = i^k E(X^k e^{itX}),$$

故 $\varphi^{(k)}(0) = i^k E(X^k)$;

(6) 对任意一组互不相同的实数 t_1, t_2, \dots, t_n , 由性质 (2) 知 $\varphi(t_i - t_j) = \overline{\varphi(t_j - t_i)}$, 则

$$[(\varphi(t_i - t_j))_{n \times n}]^T = \overline{(\varphi(t_i - t_j))_{n \times n}},$$

即矩阵 $(\varphi(t_i - t_j))_{n \times n}$ 为 Hermite 矩阵 (若为实矩阵, 就是对称阵)。对任意一组复数 c_1, c_2, \dots, c_n , 记复向量 $\alpha = (c_1, c_2, \dots, c_n)^T$, 则

$$\begin{aligned} \alpha^T (\varphi(t_i - t_j))_{n \times n} \bar{\alpha} &= \sum_{i=1}^n \sum_{j=1}^n c_i \bar{c}_j \varphi(t_i - t_j) = \sum_{i=1}^n \sum_{j=1}^n E(c_i \bar{c}_j e^{it_i X} e^{-it_j X}) = E\left(\sum_{i=1}^n \sum_{j=1}^n c_i e^{it_i X} \overline{c_j e^{it_j X}}\right) \\ &= E\left(\sum_{i=1}^n c_i e^{it_i X} \cdot \overline{\sum_{j=1}^n c_j e^{it_j X}}\right) = E\left(\left|\sum_{i=1}^n c_i e^{it_i X}\right|^2\right) \geq 0, \end{aligned}$$

故特征函数 $\varphi(t)$ 半正定;

(7) 因

$$|\varphi(t+h) - \varphi(t)| = |E(e^{i(t+h)X} - e^{itX})| \leq E(|e^{itX}(e^{ihX} - 1)|) = E(|e^{ihX} - 1|),$$

$$|e^{ihX} - 1| = |\cos(hX) - 1 + i \sin(hX)| = \sqrt{[\cos(hX) - 1]^2 + [\sin(hX)]^2} = \sqrt{2 - 2\cos(hX)}$$

$$= \left|2 \sin \frac{hX}{2}\right|,$$

因 $\lim_{c \rightarrow +\infty} P\{|X| > c\} = 0$ ，对任意正数 $\varepsilon > 0$ ，存在 $M > 0$ ，使得 $P\{|X| > M\} < \frac{\varepsilon}{3}$ ，则

$$\begin{aligned} |\varphi(t+h) - \varphi(t)| &\leq E\left|\left|2\sin\frac{hx}{2}\right|\right| = \int_{-M}^M \left|2\sin\frac{hx}{2}\right| dF(x) + \int_{|x|>M} \left|2\sin\frac{hx}{2}\right| dF(x) \\ &\leq \int_{-M}^M |hx| dF(x) + \int_{|x|>M} 2dF(x) \leq |h| \cdot M \int_{-M}^M dF(x) + 2P\{|x| > M\} < |h|M + \frac{2\varepsilon}{3}, \end{aligned}$$

取 $\delta = \frac{\varepsilon}{3M}$ ，当 $|h| < \delta$ 时，有 $|\varphi(t+h) - \varphi(t)| < \varepsilon$ ，故特征函数 $\varphi(t)$ 一致连续；

(8) 首先证明逆转公式：设 $F(x)$ 是 X 的分布函数，对于 $F(x)$ 的任意两个连续点 $x_1 < x_2$ ，满足

$$F(x_2) - F(x_1) = \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi(t) dt.$$

因

$$\int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi(t) dt = \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} E(e^{itX}) dt = \int_{-T}^T E\left[\frac{e^{it(X-x_1)} - e^{it(X-x_2)}}{it}\right] dt$$

且

$$\left|\frac{e^{it(X-x_1)} - e^{it(X-x_2)}}{it}\right| = \left|e^{it(X-x_2)} \frac{e^{it(x_2-x_1)} - 1}{it}\right| = \left|\frac{e^{it(x_2-x_1)} - 1}{it}\right| = \left|\frac{2}{t} \sin \frac{t(x_2-x_1)}{2}\right| \leq |x_2 - x_1|,$$

即 $\frac{e^{it(X-x_1)} - e^{it(X-x_2)}}{it}$ 有界，根据实变函数的 Fubini 定理知期望与积分可交换次序，有

$$\begin{aligned} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi(t) dt &= E\left[\int_{-T}^T \frac{e^{it(X-x_1)} - e^{it(X-x_2)}}{it} dt\right] \\ &= E\left[\int_{-T}^T \frac{\cos t(X-x_1) + i \sin t(X-x_1) - \cos t(X-x_2) - i \sin t(X-x_2)}{it} dt\right] \\ &= E\left[\int_{-T}^T \frac{\sin t(X-x_1) - \sin t(X-x_2)}{t} dt - i \frac{\cos t(X-x_1) - \cos t(X-x_2)}{t} dt\right] \\ &= E\left[2 \int_0^T \frac{\sin t(X-x_1) - \sin t(X-x_2)}{t} dt\right], \end{aligned}$$

根据狄利克雷积分 $\int_0^{+\infty} \frac{\sin x}{x} dx = \frac{\pi}{2}$ ，并且 $\frac{\sin x}{x}$ 是偶函数，计算 $\int_0^{+\infty} \frac{\sin at}{t} dt$ ，

当 $a > 0$ 时，令 $x = at$ ，有 $\int_0^{+\infty} \frac{\sin at}{t} dt = \int_0^{+\infty} \frac{\sin at}{at} \cdot a dt = \int_0^{+\infty} \frac{\sin x}{x} dx = \frac{\pi}{2}$ ；

当 $a < 0$ 时，令 $x = at$ ，有 $\int_0^{+\infty} \frac{\sin at}{t} dt = \int_0^{+\infty} \frac{\sin at}{at} \cdot a dt = \int_0^{-\infty} \frac{\sin x}{x} dx = -\int_{-\infty}^0 \frac{\sin x}{x} dx = -\frac{\pi}{2}$ ；

当 $a = 0$ 时， $\int_0^{+\infty} \frac{\sin at}{t} dt = 0$ ，

则 $\int_0^{+\infty} \frac{\sin at}{t} dt = \frac{\pi}{2} \operatorname{sgn}(a)$ ，可得

$$\begin{aligned}
\lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi(t) dt &= \lim_{T \rightarrow +\infty} \frac{1}{2\pi} E \left[2 \int_0^T \frac{\sin t(X - x_1) - \sin t(X - x_2)}{t} dt \right] \\
&= E \left[\frac{1}{\pi} \int_0^{+\infty} \frac{\sin t(X - x_1) - \sin t(X - x_2)}{t} dt \right] = E \left[\frac{1}{2} \operatorname{sgn}(X - x_1) - \frac{1}{2} \operatorname{sgn}(X - x_2) \right] \\
&= \int_{-\infty}^{+\infty} \frac{1}{2} [\operatorname{sgn}(x - x_1) - \operatorname{sgn}(x - x_2)] dF(x) = \int_{x_1}^{x_2} dF(x) = F(x_2) - F(x_1),
\end{aligned}$$

再根据逆转公式得分布函数的表示式。设 x 是 $F(x)$ 的任一连续点，由实变函数可知，单调不减函数 $F(x)$ 最多只有可列个不连续点，取 y 是 $F(x)$ 的连续点，并令 $y \rightarrow -\infty$ ，有

$$F(x) = \lim_{y \rightarrow -\infty} [F(x) - F(y)] = \lim_{y \rightarrow -\infty} \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ity} - e^{-itx}}{it} \varphi(t) dt,$$

故随机变量的分布函数由其特征函数唯一确定。

推论 若 X 是连续随机变量， $\varphi(t)$ 是其特征函数，如果 $\int_{-\infty}^{+\infty} |\varphi(t)| dt < +\infty$ ，则密度函数为

$$p(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-itx} \varphi(t) dx.$$

证明：因

$$F(x) = \lim_{y \rightarrow -\infty} \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ity} - e^{-itx}}{it} \varphi(t) dt,$$

记 $F_T(x, y) = \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ity} - e^{-itx}}{it} \varphi(t) dt$ 。因 $\int_{-\infty}^{+\infty} |\varphi(t)| dt < +\infty$ ，且

$$\left| \frac{e^{-ity} - e^{-itx}}{it} \right| = \left| \frac{2}{t} \sin \frac{t(x-y)}{2} \right| \leq |x-y|,$$

即 $\frac{e^{-ity} - e^{-itx}}{it}$ 一致有界，则含参变量积分 $F_T(x, y)$ 求导与积分可交换次序，可得

$$\frac{\partial}{\partial x} F_T(x, y) = \frac{1}{2\pi} \int_{-T}^T \frac{\partial}{\partial x} \left(\frac{e^{-ity} - e^{-itx}}{it} \right) \varphi(t) dt = \frac{1}{2\pi} \int_{-T}^T e^{-itx} \varphi(t) dt,$$

故

$$p(x) = F'(x) = \lim_{y \rightarrow -\infty} \lim_{T \rightarrow +\infty} \frac{\partial}{\partial x} F_T(x, y) = \lim_{T \rightarrow +\infty} \frac{1}{2\pi} \int_{-T}^T e^{-itx} \varphi(t) dt = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-itx} \varphi(t) dx.$$

注： $\varphi(t) = \int_{-\infty}^{+\infty} e^{itx} p(x) dx$ 为 $p(x)$ 的傅立叶变换，而 $p(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-itx} \varphi(t) dt$ 为 $\varphi(t)$ 的傅立叶逆变换。

一般正态分布 $N(\mu, \sigma^2)$ 可由标准正态分布 $N(0, 1)$ 通过线性变换得到，因此根据性质 (3) 由标准正态分布 $N(0, 1)$ 的特征函数得到一般正态分布 $N(\mu, \sigma^2)$ 的特征函数。

设 $X \sim N(\mu, \sigma^2)$ ，有 $Y = \frac{X - \mu}{\sigma} \sim N(0, 1)$ ， Y 的特征函数为 $\varphi_Y(t) = e^{-\frac{t^2}{2}}$ ，且 $X = \sigma Y + \mu$ ，故一般正

态分布 $N(\mu, \sigma^2)$ 的特征函数为

$$\varphi_X(t) = \varphi_{\sigma Y + \mu}(t) = e^{i\mu t} \varphi_Y(\sigma t) = e^{i\mu t} e^{-\frac{\sigma^2 t^2}{2}} = e^{i\mu t - \frac{\sigma^2 t^2}{2}}.$$

例 利用特征函数性质证明正态分布的可加性：若 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 且 X 与 Y 相互独立, 则 $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 。

证明：因 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 且 X 与 Y 相互独立, 可得 X 与 Y 的特征函数分别为

$$\varphi_X(t) = e^{i\mu_1 t - \frac{\sigma_1^2 t^2}{2}}, \quad \varphi_Y(t) = e^{i\mu_2 t - \frac{\sigma_2^2 t^2}{2}},$$

则 $X + Y$ 的特征函数为

$$\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t) = e^{i(\mu_1 + \mu_2)t - \frac{(\sigma_1^2 + \sigma_2^2)t^2}{2}},$$

这正是正态分布 $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 的特征函数, 故根据特征函数的唯一性可知

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)。$$

注：此结论可推广到多个随机变量, 设 X_1, X_2, \dots, X_n 相互独立, 且 $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, 2, \dots, n$, 则有

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)。$$

例 证明泊松分布的正态逼近：设 $X \sim P(\lambda)$, 记 X 的标准化随机变量为 $Y_\lambda = \frac{X - \lambda}{\sqrt{\lambda}}$, 则 Y_λ 按分布收敛于标准正态分布 $N(0, 1)$ 。

证明：因 $X \sim P(\lambda)$, 有 X 的特征函数为 $\varphi(t) = e^{\lambda(e^{it} - 1)}$, 而

$$Y_\lambda = \frac{X - \lambda}{\sqrt{\lambda}} = \frac{1}{\sqrt{\lambda}} X - \sqrt{\lambda},$$

其特征函数为

$$\varphi_{Y_\lambda}(t) = e^{-i\sqrt{\lambda}t} \varphi\left(\frac{t}{\sqrt{\lambda}}\right) = e^{-i\sqrt{\lambda}t} \cdot e^{\lambda(e^{\frac{it}{\sqrt{\lambda}}} - 1)} = e^{\lambda(e^{\frac{it}{\sqrt{\lambda}}} - 1) - \frac{it}{\sqrt{\lambda}}}。$$

因 $e^x = 1 + x + \frac{x^2}{2} + o(x^2)$, 即

$$e^{\frac{iv}{\sqrt{\lambda}}} = 1 + \frac{iv}{\sqrt{\lambda}} + \frac{-v^2}{2\lambda} + o\left(\frac{1}{\lambda}\right),$$

$$e^{\frac{iv}{\sqrt{\lambda}}} - 1 - \frac{iv}{\sqrt{\lambda}} = -\frac{v^2}{2\lambda} + o\left(\frac{1}{\lambda}\right),$$

$$\lim_{\lambda \rightarrow +\infty} \varphi_{Y_\lambda}(t) = \lim_{\lambda \rightarrow +\infty} e^{\lambda(e^{\frac{it}{\sqrt{\lambda}}} - 1) - \frac{it}{\sqrt{\lambda}}} = \lim_{\lambda \rightarrow +\infty} e^{\lambda\left[-\frac{v^2}{2\lambda} + o\left(\frac{1}{\lambda}\right)\right]} = \lim_{\lambda \rightarrow +\infty} e^{-\frac{v^2}{2} + o(1)} = e^{-\frac{v^2}{2}},$$

这正是标准正态分布的特征函数, 则根据特征函数的唯一性可知, $\lim_{\lambda \rightarrow +\infty} F_{Y_\lambda}(y) = \Phi(y)$, 故 Y_λ 按分布收敛于标准正态分布。

§4.3 大数定律

在大量的重复试验中, 频率稳定于概率, 平均值稳定于数学期望。直观上, 这里的“稳定”类似于数学分析中的极限, 但又有差别, 本节将在数学上给予严格表述, 并证明上述结论。

4.3.1 伯努利大数定律 (Bernoulli Law of Large Numbers)

设事件 A 在每次试验中发生的概率为 p , 在 n 重伯努利试验中的发生次数为 S_n , 即频率为 $\frac{S_n}{n}$ 。直观上, 随 n 的无限增大, 频率 $\frac{S_n}{n}$ 将以概率 p 为“极限”。

定理 (伯努利大数定律) 设 S_n 为 n 重伯努利试验中事件 A 的发生次数, p 为每次试验中 A 发生的概率, 则对任意的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow +\infty} P\left\{\left|\frac{S_n}{n} - p\right| < \varepsilon\right\} = 1。$$

证明: 因 S_n 服从二项分布 $b(n, p)$, 有 $E(S_n) = np$, $\text{Var}(S_n) = np(1-p)$, 则

$$E\left(\frac{S_n}{n}\right) = \frac{1}{n} E(S_n) = \frac{1}{n} \cdot np = p,$$

$$\text{Var}\left(\frac{S_n}{n}\right) = \frac{1}{n^2} \text{Var}(S_n) = \frac{1}{n^2} \cdot np(1-p) = \frac{p(1-p)}{n},$$

由切比雪夫不等式, 可得

$$1 \geq P\left\{\left|\frac{S_n}{n} - p\right| < \varepsilon\right\} \geq 1 - \frac{\text{Var}\left(\frac{S_n}{n}\right)}{\varepsilon^2} = 1 - \frac{p(1-p)}{n\varepsilon^2},$$

因 $\lim_{n \rightarrow +\infty} \left[1 - \frac{p(1-p)}{n\varepsilon^2}\right] = 1$, 故由夹逼准则可得

$$\lim_{n \rightarrow +\infty} P\left\{\left|\frac{S_n}{n} - p\right| < \varepsilon\right\} = 1。$$


伯努利大数定律表明频率依概率收敛于概率 p , 这就是在大量重复试验中频率稳定于概率 p 的含义。

注: 此定理又称为弱大数定律, 此外还有强大数定律, 即频率几乎处处收敛收敛于概率 p 。

现在常用的统计模拟方法, 蒙特卡洛方法 (Monte Carlo method) 中的随机投点法就是依据伯努利大数定律, 以计算机为模拟工具, 进行大量重复试验, 用频率作为概率的估计值进行计算。

如计算定积分 $\int_0^1 f(x)dx$, 且 $0 \leq f(x) \leq 1$ 。设随机变量 (X, Y) 服从区域 $D = \{(x, y) | 0 \leq x \leq 1, 0 \leq y \leq 1\}$ 上的均匀分布, 且区域 $G = \{(x, y) | 0 \leq x \leq 1, 0 \leq y \leq f(x)\}$, 则

$$P\{(X, Y) \in G\} = \frac{\text{区域 } G \text{ 的面积}}{\text{区域 } D \text{ 的面积}} = \int_0^1 f(x)dx。$$



这样, 首先用计算机产生在 $(0, 1)$ 区间上均匀分布的 n 对随机数 (x_i, y_i) , $i = 1, 2, \dots, n$, 记录其中满足

不等式 $y_i \leq f(x_i)$ 的数据对的个数 S_n ，用频率 $\frac{S_n}{n}$ 作为概率 $P\{(X,Y) \in G\}$ 的估计值，这样就得到 $\int_0^1 f(x)dx$ 的估计值。

对于一般的定积分 $\int_a^b g(x)dx$ ，可通过变量替换 $y = \frac{x-a}{b-a}$ 化为关于 y 的函数在 0 与 1 之间的积分，即

$$\int_a^b g(x)dx = (b-a) \int_0^1 g[a + (b-a)y]dy,$$

进一步，若 $m \leq g(x) \leq M$ ，通过函数变换 $f(y) = \frac{g[a + (b-a)y] - m}{M - m}$ ，使得 $0 \leq f(y) \leq 1$ ，可得

$$\int_a^b g(x)dx = (b-a)(M-m) \int_0^1 f(y)dy + m(b-a),$$

这样，用蒙特卡洛方法计算出 $\int_0^1 f(y)dy$ ，进而就得到 $\int_a^b g(x)dx$ 的值。

附：用蒙特卡洛随机投点法计算定积分 $\int_0^1 \frac{1}{1+x^2} dy$ ，MATLAB 程序：

```
n=input('number of tests=');k=0;
for i=1:n
    x=rand;y=rand;
    if y<=1/(1+x^2);
        k=k+1;
    end
end
J=k/n
```

4.3.2 常用的几个大数定律

一. 大数定律的一般形式

直观上，在大量重复试验中，平均值稳定于数学期望，也就是对于一个随机变量序列 $\{X_n\}$ ，其平均值

$\frac{1}{n} \sum_{i=1}^n X_i$ 将依概率收敛于其数学期望 $\frac{1}{n} \sum_{i=1}^n E(X_i)$ 。

定义 设随机变量序列 $\{X_n\}$ 满足

$$\lim_{n \rightarrow +\infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i) \right| < \varepsilon \right\} = 1,$$

则称 $\{X_n\}$ 服从大数定律。

伯努利大数定律中，设 S_n 表示 n 重伯努利试验中事件 A 的发生次数， p 表示每次试验中 A 发生的概率，

令

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 次试验中事件 } A \text{ 发生;} \\ 0, & \text{第 } i \text{ 次试验中事件 } A \text{ 没有发生.} \end{cases} \quad i = 0, 1, 2, \dots,$$

则有 $S_n = \sum_{i=1}^n X_i$ ，且频率 $\frac{S_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$ ，概率 $p = \frac{1}{n} \sum_{i=1}^n E(X_i)$ ，可见伯努利大数定律也就是说明 n 重伯努

利试验中事件 A 在每次试验中的发生情况 $\{X_n\}$ 服从大数定律。

此外, 还有一些其它的大数定律, 分别说明对于随机变量序列 $\{X_n\}$, 在满足某些不同的条件下, 将服从大数定律。

二. 切比雪夫大数定律 (Chebyshev Law of Large Numbers)

定理 (切比雪夫大数定律) 设 $\{X_n\}$ 是两两不相关的随机变量序列, 每个 X_n 的方差都存在且有共同的上界, 即 $\text{Var}(X_n) \leq c, n=1, 2, \dots$, 则 $\{X_n\}$ 服从大数定律, 即对任意的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow +\infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right\} = 1。$$

证明: 因 $\{X_n\}$ 两两不相关, 有

$$E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i), \quad \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \leq \frac{1}{n^2} \cdot nc = \frac{c}{n},$$

由切比雪夫不等式, 可得

$$1 \geq P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right\} \geq 1 - \frac{1}{\varepsilon^2} \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = 1 - \frac{c}{n\varepsilon^2},$$

因 $\lim_{n \rightarrow +\infty} \left(1 - \frac{c}{n\varepsilon^2}\right) = 1$, 故由夹逼准则可得

$$\lim_{n \rightarrow +\infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \varepsilon\right\} = 1。$$

伯努利大数定律的条件要求 $\{X_n\}$ 独立, 且都服从相同的两点分布, 而切比雪夫大数定律的条件只要求 $\{X_n\}$ 两两不相关, 不必同分布, 只需要方差存在且有共同的上界, 条件比伯努利大数定律放宽。

三. 马尔可夫大数定律 (Markov Law of Large Numbers)

在切比雪夫大数定律的证明过程中, 可以看出只要随机变量序列 $\{X_n\}$ 满足 $\lim_{n \rightarrow +\infty} \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = 0$, 就能证明 $\{X_n\}$ 满足大数定律。

定理 (马尔可夫大数定律) 设随机变量序列 $\{X_n\}$ 满足

$$\lim_{n \rightarrow +\infty} \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = 0,$$

则 $\{X_n\}$ 服从大数定律, 即对任意的 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow +\infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i) \right| < \varepsilon \right\} = 1.$$

证明：由切比雪夫不等式，就可证得。

马尔可夫大数定律的条件更加放宽，去掉了 $\{X_n\}$ 两两独立或不相关的条件，只需要它们的方差满足一定的有界条件即可。

四．辛钦大数定律 (Wiener-khinchin Law of Large Numbers)

定理 (辛钦大数定律) 设 $\{X_n\}$ 是独立同分布的随机变量序列，且数学期望 $E(X_n) = \mu$ 存在，则 $\{X_n\}$ 服从大数定律，即对任意的 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow +\infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \varepsilon \right\} = 1.$$

证明：因 $\{X_n\}$ 独立同分布，设 X_n 的特征函数为 $\varphi(t)$ ，记 $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$ ，有 Y_n 的特征函数为

$$\varphi_{Y_n}(t) = \left[\varphi\left(\frac{t}{n}\right) \right]^n,$$

因 $\varphi(0) = 1$ ， $\varphi'(0) = iE(X_n) = i\mu$ ，有 $\varphi(t) = \varphi(0) + \varphi'(0)t + o(t) = 1 + i\mu t + o(t)$ ，即

$$\varphi\left(\frac{t}{n}\right) = 1 + \frac{i\mu t}{n} + o\left(\frac{1}{n}\right),$$

则

$$\lim_{n \rightarrow +\infty} \varphi_{Y_n}(t) = \lim_{n \rightarrow +\infty} \left[1 + \frac{i\mu t}{n} + o\left(\frac{1}{n}\right) \right]^n = \lim_{n \rightarrow +\infty} \left[1 + \frac{i\mu t}{n} \right]^n = e^{i\mu t},$$

这正是在 μ 点处单点分布的特征函数，故 Y_n 按分布收敛于 μ ，即 $Y_n = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{L} \mu$ ，可得 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu$ 。

蒙特卡洛方法中的平均值法就是依据辛钦大数定律，以计算机为模拟工具，进行大量重复试验，用平均值作为数学期望的估计值进行计算。

如计算定积分 $\int_0^1 f(x)dx$ 。设随机变量 X 服从均匀分布 $U(0, 1)$ ，有 $E[f(X)] = \int_0^1 f(x)dx$ 。

首先用计算机产生在 $(0, 1)$ 区间上均匀分布的 n 个随机数 x_i ， $i = 1, 2, \dots, n$ ，再用平均值 $\frac{1}{n} \sum_{i=1}^n f(X_i)$ 作

为数学期望 $E[f(X)]$ 的估计值，即得到 $\int_0^1 f(x)dx$ 的估计值。

附：用蒙特卡洛平均值法计算定积分 $\int_0^1 \frac{1}{1+x^2} dy$ ，MATLAB 程序：

```
n=input('number of tests=');
x=rand(n,1); y=1./(1+x.^2);
J=mean(y)
```


§4.4 中心极限定理

4.4.1 独立随机变量和

现实生活中,许多随机现象都是众多独立随机因素共同影响的结果,中心极限定理研究独立随机变量和的分布,证明了在一定条件下,独立随机变量和的分布逼近一个正态分布。

设 $\{X_n\}$ 是独立随机变量序列,记 $Y_n = \sum_{k=1}^n X_k$, 并标准化,可得 $Y_n^* = \frac{Y_n - E(Y_n)}{\sqrt{\text{Var}(Y_n)}}$, 下面将证明当 $\{X_n\}$ 满足某些条件时, Y_n^* 按分布收敛于标准正态分布 $N(0, 1)$ 。

4.4.2 独立同分布下的中心极限定理 (Central Limit Theorem)

定理 (林德贝格-列维中心极限定理) 设随机变量序列 $\{X_n\}$ 独立同分布, 且数学期望 $E(X_i) = \mu$,

方差 $\text{Var}(X_i) = \sigma^2 > 0$, 记 $Y_n^* = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}}$, 则 Y_n^* 按分布收敛于标准正态分布 $N(0, 1)$, 即对任意实数 y ,

有

$$\lim_{n \rightarrow +\infty} P\{Y_n^* \leq y\} = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{t^2}{2}} dt.$$

证明: 设 $X_i - \mu$ 的特征函数为 $\varphi(t)$, 有 $Y_n^* = \frac{1}{\sigma\sqrt{n}} \sum_{i=1}^n (X_i - \mu)$ 的特征函数为

$$\varphi_{Y_n^*}(t) = \left[\varphi\left(\frac{t}{\sigma\sqrt{n}}\right) \right]^n.$$

因 $E(X_i - \mu) = 0$, $\text{Var}(X_i - \mu) = \sigma^2 > 0$, 有

$$\varphi(0) = 1, \quad \varphi'(0) = iE(X_i - \mu) = 0, \quad \varphi''(0) = i^2 E(X_i - \mu)^2 = -\sigma^2,$$

可得

$$\varphi(t) = \varphi(0) + \varphi'(0)t + \frac{1}{2}\varphi''(0)t^2 + o(t^2) = 1 - \frac{\sigma^2 t^2}{2} + o(t^2),$$

$$\varphi\left(\frac{t}{\sigma\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right),$$

则

$$\lim_{n \rightarrow +\infty} \varphi_{Y_n^*}(t) = \lim_{n \rightarrow +\infty} \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right]^n = \lim_{n \rightarrow +\infty} \left[1 - \frac{t^2}{2n} \right]^n = e^{-\frac{t^2}{2}},$$

这正是标准正态分布的特征函数, 故 Y_n^* 按分布收敛于标准正态分布 $N(0, 1)$, $\lim_{n \rightarrow +\infty} F_{Y_n^*}(y) = \Phi(y)$, 即

$$\lim_{n \rightarrow +\infty} P\{Y_n^* \leq y\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{t^2}{2}} dt.$$

林德贝格-列维中心极限定理说明独立同分布随机变量序列, 无论服从什么分布, 只要其数学期望存在, 方差大于 0, 其随机变量和的分布都逼近一个正态分布。

4.4.3 二项分布的正态近似

将林德贝格-列维中心极限定理用于二项分布 (独立同分布的两点分布之和), 即得

定理 (棣莫弗-拉普拉斯中心极限定理) 设 n 重伯努利试验中事件 A 的发生次数为 S_n , 每次试验中 A

发生的概率为 p ($0 < p < 1$), 记 $Y_n^* = \frac{S_n - np}{\sqrt{np(1-p)}}$, 则 Y_n^* 按分布收敛于标准正态分布 $N(0, 1)$, 即对任意

实数 y , 有

$$\lim_{n \rightarrow +\infty} P\{Y_n^* \leq y\} = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{t^2}{2}} dt.$$

棣莫弗-拉普拉斯定理是历史上第一个中心极限定理。

4.4.4 独立不同分布下的中心极限定理

现实生活中, 影响一个随机变量的众多随机因素并不都是同分布的。直观上, 只要每一个因素的影响都很小, 其标准化随机变量的极限分布将服从标准正态分布。

设 $\{X_n\}$ 是独立随机变量序列, 且 $E(X_i) = \mu_i$, $\text{Var}(X_i) = \sigma_i^2$, $i = 1, 2, \dots$, 记

$$Y_n^* = \frac{\sum_{i=1}^n X_i - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}} = \frac{1}{\sqrt{\sum_{i=1}^n \sigma_i^2}} \sum_{i=1}^n (X_i - \mu_i),$$

并记 $B_n = \sqrt{\sum_{i=1}^n \sigma_i^2}$, 即 $Y_n^* = \frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i)$ 。

为了使得 Y_n^* 中每一项 $\frac{X_i - \mu_i}{B_n}$ 影响都很小, 即对任意的 $\tau > 0$, 要求概率 $P\{|X_i - \mu_i| > \tau B_n\}$ 很小, 而

$$P\{|X_i - \mu_i| > \tau B_n\} = \int_{|x - \mu_i| > \tau B_n} p_i(x) dx \leq \frac{1}{\tau^2 B_n^2} \int_{|x - \mu_i| > \tau B_n} (x - \mu_i)^2 p_i(x) dx,$$

这样, 令

$$\lim_{n \rightarrow +\infty} \frac{1}{\tau^2 B_n^2} \sum_{i=1}^n \int_{|x - \mu_i| > \tau B_n} (x - \mu_i)^2 p_i(x) dx = 0,$$

就可保证 Y_n^* 中每一项 $\frac{X_i - \mu_i}{B_n}$ 的影响都很小, 这称之为林德贝格条件。不加证明地给出以下定理。

定理 (林德贝格中心极限定理) 独立随机变量序列 $\{X_n\}$, $E(X_i) = \mu_i$, $\text{Var}(X_i) = \sigma_i^2$, $i = 1, 2, \dots$,

记 $B_n = \sqrt{\sum_{i=1}^n \sigma_i^2}$, $Y_n^* = \frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i)$ 。如果对任意的 $\tau > 0$, $\{X_n\}$ 满足林德贝格条件

$$\lim_{n \rightarrow +\infty} \frac{1}{\tau^2 B_n^2} \sum_{i=1}^n \int_{|x-\mu_i| > \tau B_n} (x-\mu_i)^2 p_i(x) dx = 0,$$

则 Y_n^* 按分布收敛于标准正态分布 $N(0, 1)$ ，即对任意实数 y ，有

$$\lim_{n \rightarrow +\infty} P\{Y_n^* \leq y\} = \lim_{n \rightarrow +\infty} P\left\{\frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) \leq y\right\} = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{t^2}{2}} dt.$$

林德贝格条件要求比较宽，但较难验证，而下面的李雅普诺夫条件虽然比林德贝格条件要求稍严格一些，却比较容易验证。不加证明地给出以下定理。

定理 (李雅普诺夫中心极限定理) 独立随机变量序列 $\{X_n\}$ ， $E(X_i) = \mu_i$ ， $\text{Var}(X_i) = \sigma_i^2$ ， $i = 1, 2, \dots$ ，

记 $B_n = \sqrt{\sum_{i=1}^n \sigma_i^2}$ ， $Y_n^* = \frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i)$ 。如果存在 $\delta > 0$ ， $\{X_n\}$ 满足李雅普诺夫条件

$$\lim_{n \rightarrow +\infty} \frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E(|X_i - \mu_i|^{2+\delta}) = 0,$$

则 Y_n^* 按分布收敛于标准正态分布 $N(0, 1)$ ，即对任意实数 y ，有

$$\lim_{n \rightarrow +\infty} P\{Y_n^* \leq y\} = \lim_{n \rightarrow +\infty} P\left\{\frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) \leq y\right\} = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-\frac{t^2}{2}} dt.$$

4.4.5 中心极限定理应用举例

中心极限定理基本思想：如果一个随机变量受众多随机因素的影响，并且每一个因素的影响都很小，则其标准化随机变量将服从标准正态分布。

一般当 n 很大时，随机变量之和、二项分布等经标准化后等都可用标准正态分布 $N(0, 1)$ 近似。

对于取值整数的离散随机变量，如二项分布、泊松分布，如果用中心极限定理作正态分布近似计算，可将每个整数点取值的概率看作分散分布在该点 ± 0.5 区间之内，求概率时最好是将取值范围的整数通过加或减 0.5 进行修正。如概率 $P\{k_1 \leq X \leq k_2\}$ 修正为 $P\{k_1 - 0.5 < X \leq k_2 + 0.5\}$ ，而概率 $P\{k_1 < X < k_2\}$ 修正为 $P\{k_1 + 0.5 < X \leq k_2 - 0.5\}$ 。

例 从一大批次品率为 10% 的产品中，随机抽取 400 件，求次品数超过 50 件的概率，次品数在 36 到 44 件之间的概率以及次品数恰为 40 件的概率。

解： 设 X 表示取得的次品数，有 $X \sim b(400, 0.1)$ 。因 $n = 400$ 很大，且数学期望 $E(X) = np = 40$ ，方差 $\text{Var}(X) = np(1-p) = 36$ ，有 $\frac{X-40}{6} \sim N(0, 1)$ ，所求概率为

$$P\{X > 50\} = P\{X > 50.5\} \approx 1 - \Phi\left(\frac{50.5 - 40}{6}\right) = 1 - \Phi(1.75) = 1 - 0.9599 = 0.0401;$$

$$\begin{aligned} P\{36 \leq X \leq 44\} &= P\{35.5 < X < 44.5\} \approx \Phi\left(\frac{44.5 - 40}{6}\right) - \Phi\left(\frac{35.5 - 40}{6}\right) = \Phi(0.75) - \Phi(-0.75) \\ &= 2\Phi(0.75) - 1 = 2 \times 0.7734 - 1 = 0.5468; \end{aligned}$$

$$P\{X = 40\} = P\{39.5 < X < 40.5\} \approx \Phi\left(\frac{40.5 - 40}{6}\right) - \Phi\left(\frac{39.5 - 40}{6}\right) = \Phi(0.0833) - \Phi(-0.0833) \\ = 2\Phi(0.0833) - 1 = 2 \times 0.5332 - 1 = 0.0664。$$

例 掷硬币 100 次，求正面朝上的频率超过 0.6 的概率。

解：设 X 表示正面朝上的次数，有 $X \sim b(100, 0.5)$ 。频率 $\frac{X}{100} > 0.6$ ，即 $X > 60$ 。因 $n = 100$ 较大，且数学期望 $E(X) = np = 50$ ，方差 $\text{Var}(X) = np(1-p) = 25$ ，有 $\frac{X-50}{5} \sim N(0, 1)$ ，所求概率为

$$P\{X > 60\} = P\{X > 60.5\} \doteq 1 - \Phi\left(\frac{60.5 - 50}{5}\right) = 1 - \Phi(2.1) = 1 - 0.9821 = 0.0179。$$

例 一商店中某商品日销量服从参数 $\lambda = 4$ 的泊松分布，每月月初进货，问月初进货后应库存多少件，才能以 99% 以上的概率满足本月的需要？（每月以 30 天计，且每日销量相互独立）

解：以 X_i 表示第 i 日的销量， $X_i \sim P(4)$ 且相互独立，有 $E(X_i) = \lambda = 4$ ， $\text{Var}(X_i) = \lambda = 4$ ，月销量为

$\sum_{i=1}^{30} X_i$ 。因 $n = 30$ 较大，且 $E\left(\sum_{i=1}^{30} X_i\right) = 30 \times 4 = 120$ ， $\text{Var}\left(\sum_{i=1}^{30} X_i\right) = 30 \times 4 = 120$ ，有 $\frac{\sum_{i=1}^{30} X_i - 120}{\sqrt{120}} \sim N(0, 1)$ 。

设月初应库存 x 件该商品，事件“满足本月的需要”，即 $\sum_{i=1}^{30} X_i \leq x$ ，所求概率为

$$P\left\{\sum_{i=1}^n X_i \leq x\right\} = P\left\{\frac{\sum_{i=1}^n X_i - 120}{\sqrt{120}} \leq \frac{x-120}{\sqrt{120}}\right\} \approx \Phi\left(\frac{x-120}{\sqrt{120}}\right) \geq 0.99，$$

有 $\frac{x-120}{\sqrt{120}} \geq 2.3263$ ，故 $x \geq 145.4839$ ，取 $x = 146$ 。

例 每个元件使用寿命（小时）服从指数分布 $\text{Exp}\left(\frac{1}{1000}\right)$ ，求：（1）一个元件使用寿命在 800 到 1200 小时之间的概率；（2）100 个元件平均寿命在 800 到 1200 小时之间的概率。

解：以 X_i 表示第 i 个元件的使用寿命，则 X_i 的密度函数为

$$p(x) = \begin{cases} \frac{1}{1000} e^{-\frac{x}{1000}}, & x > 0; \\ 0, & x \leq 0. \end{cases}$$

且 $E(X_i) = \frac{1}{\lambda} = 1000$ ， $\text{Var}(X_i) = \frac{1}{\lambda^2} = 10^6$ 。

（1）一个元件直接根据指数分布进行计算

$$P\{800 < X_i < 1200\} = \int_{800}^{1200} \frac{1}{1000} e^{-\frac{x}{1000}} dx = -e^{-\frac{x}{1000}} \Big|_{800}^{1200} = e^{-0.8} - e^{-1.2} = 0.1481；$$

(2) 100 个元件平均寿命 $\bar{X} = \frac{1}{100} \sum_{i=1}^{100} X_i$, 因 $n=100$ 较大, 且 X_i 相互独立, 有

$$E\left(\sum_{i=1}^{100} X_i\right) = \sum_{i=1}^{100} E(X_i) = 10^5, \quad \text{Var}\left(\sum_{i=1}^{100} X_i\right) = \sum_{i=1}^{100} \text{Var}(X_i) = 10^8,$$

$$\text{即 } \frac{\sum_{i=1}^{100} X_i - 10^5}{10^4} = \frac{\bar{X} - 1000}{100} \sim N(0, 1), \text{ 故}$$

$$P\{800 < \bar{X} < 1200\} = P\left\{-2 < \frac{\bar{X} - 1000}{100} < 2\right\} = \Phi(2) - \Phi(-2) = 2 \times 0.9772 - 1 = 0.9544.$$

例 讨论各国足球联赛理论保级分。

背景: 如英超、意甲、西甲、法甲, 共 20 支足球队, 每年双循环比赛。每轮比赛 10 场, 全年共 38 轮。每场比赛胜得 3 分, 平得 1 分, 负得 0 分。全年比赛得分最低的 3 支球队降级。

假设: 各球队实力相当, 每场比赛胜、平、负的概率各占三分之一; 每场比赛结果相互独立。

分析: 设 X_i 表示某球队第 i 轮比赛的得分, 其分布列为

X_i	0	1	3
P	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{3}$

则

$$E(X_i) = 0 \times \frac{1}{3} + 1 \times \frac{1}{3} + 3 \times \frac{1}{3} = \frac{4}{3}, \quad \text{Var}(X_i) = E(X_i^2) - [E(X_i)]^2 = \frac{10}{3} - \left(\frac{4}{3}\right)^2 = \frac{14}{9},$$

该队 38 轮总分 $\sum_{i=1}^{38} X_i$, $n=38$ 较大,

$$E\left(\sum_{i=1}^{38} X_i\right) = 38 \times \frac{4}{3} \approx 50.67, \quad \text{Var}\left(\sum_{i=1}^{38} X_i\right) = 38 \times \frac{14}{9} \approx 59.11,$$

则 $\frac{\sum_{i=1}^{38} X_i - 50.67}{\sqrt{59.11}} \sim N(0, 1)$, 设 x 为理论保级分, 即 $\sum_{i=1}^{38} X_i \geq x$ 表示保级。又已知 20 支球队中有 3 支降级,

17 支保级, 则

$$P\left\{\sum_{i=1}^{38} X_i \geq x\right\} = 1 - \Phi\left(\frac{x - 50.67}{\sqrt{59.11}}\right) = \frac{17}{20} = 0.85, \quad -\frac{x - 50.67}{\sqrt{59.11}} = 1.0364,$$

故 $x = 42.6982$, 取 $x = 43$, 英超足球联赛理论保级分为 43 分。

一般地, 设共有 n 支足球队, 每年双循环比赛, 全年共 $2n-2$ 轮, 全年比赛得分最低的 m 支球队降级,

则理论保级分为 $x = \frac{4}{3}(2n-2) - \sqrt{\frac{14}{9}(2n-2)} \cdot \Phi^{-1}\left(1 - \frac{m}{n}\right)$, 其中 $\Phi(\cdot)$ 表示标准正态分布的分布函数。